

Machine learning models for Navier-Stocks

Боева Галина, группа M05-304a

16 ноября 2024 г.

1 Введение

Симуляция физических процессов, таких как движение жидкостей, является важной задачей в науке и инженерии. Традиционные методы часто используют графовые структуры для определения взаимодействий между частицами, что может быть неэффективно для описания непрерывных процессов, таких как механика жидкостей. В данной статье авторы предлагают альтернативный подход, основанный на лагранжевой модели и непрерывных свертках, что позволяет более точно и быстро моделировать поведение жидкостей.

2 Основные подходы в теме

Лагранжева модель: Использует набор частиц для представления жидкости, где каждая частица несет локальные свойства, такие как скорость и плотность.

Методы сглаженной гидродинамики (SPH): Популярный подход для моделирования жидкостей, который использует частичные дифференциальные уравнения для описания динамики.

Графовые структуры: Традиционные методы используют графы для определения взаимодействий между частицами, что может усложнять модель при больших масштабах.

2.1 Лагранжевые координаты

Лагранжевые координаты описывают положение частиц или элементов системы в зависимости от времени. Если $\mathbf{x}_i(t)$ — положение частицы i в момент времени t , то её скорость $\mathbf{v}_i(t)$ определяется как производная по времени:

$$\mathbf{v}_i(t) = \frac{d\mathbf{x}_i(t)}{dt} \quad (1)$$

2.2 Уравнения движения

Уравнения движения для частиц в лагранжевых координатах могут быть записаны в виде:

$$\frac{d\mathbf{x}_i(t)}{dt} = \mathbf{v}_i(t) \quad (2)$$

$$\frac{d\mathbf{v}_i(t)}{dt} = \mathbf{a}_i(t) \quad (3)$$

где $\mathbf{a}_i(t)$ — ускорение частицы i , которое может зависеть от различных сил, действующих на частицу.

3 Основные формулы и алгоритм действий

3.1 Непрерывные свертки

Авторы рассматривают жидкости как пространственно непрерывные функции, отобранные в конечном наборе (непрерывно меняющихся) положений, и обрабатывают их с помощью нового слоя непрерывной свертки. Это более точно соответствует непрерывному характеру задачи и упрощает определение нейронных сетей за счет абстрагирования от представления частиц, лежащего в их основе.

Авторы расширили представление фильтров на основе сетки, обычно используемое для дискретных сверток, до непрерывной области с помощью простой линейной интерполяции. Линейная интерполяция фильтров позволяет эффективно искать пространственно изменяющиеся значения фильтров в произвольных точках, сохраняя при этом компактность и эффективность представления в виде сетки. Кроме того, авторы используют функцию окна для определения поддержки фильтров и отображение шара в куб для поддержки сферических полей восприятия.

Авторы показали, что их свертки, несмотря на их простоту, работают лучше, чем более сложные представления.

3.2 Уравнения Навье-Стокса

Жидкости изучаются уже несколько веков, и уравнения Навье-Стокса для несжимаемых жидкостей хорошо установлены (Батчелор, 1967):

$$\frac{\partial \mathbf{v}}{\partial t} + \mathbf{v} \cdot \nabla \mathbf{v} = -\frac{1}{\rho} \nabla p + \nu \nabla^2 \mathbf{v} + \mathbf{g}, \quad \text{при условии} \quad \nabla \cdot \mathbf{v} = 0. \quad (4)$$

4 Метод решения

Одним из распространенных методов решения этих дифференциальных уравнений является аппроксимация жидкости набором гладких частиц. Каждая частица соответствует непрерывному объему вещества и несет локальные свойства жидкости, такие как скорость и плотность, которые движутся с потоком. Это мотивировано тем, что функция $A(\mathbf{x})$ может быть представлена интегральной интерполяцией:

$$A(\mathbf{x}) = \int A(\mathbf{x}') \delta(\|\mathbf{x} - \mathbf{x}'\|^2) dV(\mathbf{x}'), \quad (5)$$

где $\delta(\mathbf{x})$ обозначает дельта-функцию Дирака. Это уравнение может быть дискретизировано как:

$$A(\mathbf{x}) \approx \sum_i V_i A_i W(\|\mathbf{x} - \mathbf{x}'\|^2, h), \quad (6)$$

где V_i — объем в данной точке пространства, и

$$\lim_{h \rightarrow 0} W(\|\mathbf{x} - \mathbf{x}'\|, h) = \delta(\|\mathbf{x} - \mathbf{x}'\|). \quad (7)$$

Здесь $W(\mathbf{x}, h)$ — гладкое ядро или свертка с радиусом h , обычно в виде гауссового распределения, но могут использоваться и более сложные функции. В практике ядро конечно и дает локализованные окрестности частиц, которые взаимодействуют через взаимодействия, взвешенные производными ядра. Таким образом, непрерывное описание жидкостей из уравнения (1) может быть дискретизировано в лагранжевом виде и решено численно. Обычно внутренние силы рассчитываются на основе локального давления, вязкости и поверхностного натяжения, что дает обновление для положения каждой частицы.

5 Дискретная свертка

Оператор дискретной свертки, обычно используемый в ConvNets, определяется как:

$$(f * g)(x) = \sum_{\tau \in \Omega} f(x + \tau) g(\tau), \quad (8)$$

где f и g — входная функция и фильтр, x — положение, τ — вектор сдвига, а Ω — множество векторов сдвига, определяющее поддержку фильтра. На регулярных данных, таких как изображения, положения x варьируются по регулярной сетке, а векторы сдвига τ являются целочисленными, т.е. $x, \tau \in \mathbb{Z}^d$ для некоторой размерности d . Аналогично в непрерывной области эта свертка определяется как:

$$(f * g)(x) = \int_{\mathbb{R}^d} f(x + \tau) g(\tau) d\tau, \quad (9)$$

где x и τ — вещественные векторы, т.е. $x, \tau \in \mathbb{R}^d$.

6 Адаптация к неструктурированным облакам точек

Теперь адаптируем это определение к неструктурированным облакам точек. В этом случае у нас есть конечное число точек, которые дискретизируют функцию f , но не лежат на сетке. Для облака точек с $i = 1, \dots, N$ точками со значениями f_i в положениях x_i , мы определяем свертку в положении x как:




Рис. 1: Используются сферические формы фильтров для наших непрерывных сверток, но используем обычные сетки для хранения значений фильтров. В левой части рисунка показана сферическая область радиусом R и точка с относительными координатами $\mathbf{r}$ относительно центра. Далее следует преобразование $\mathbf{r}$ через отображение Λ в нормализованные координаты в обычной сетке. Тонкие пунктирные линии иллюстрируют искажение отображения. Для поиска конечного значения фильтра мы используем трехлинейную интерполяцию в обычной сетке.

$$(f * g)(x) = \frac{1}{\psi(x)} \sum_{i \in N(x, R)} a(x_i, x) f_i g(\Lambda(x_i - x)), \quad (10)$$

где $N(x, R)$ — множество точек в радиусе R вокруг x . a — скалярная функция, которая может использоваться для нормализации плотности, специфичной для точек x_i и x . В простейшем случае a может быть постоянной: $a = 1$. В нашем случае мы хотим обеспечить плавный отклик нашей свертки при изменении соседства частиц, поэтому определяем a как функцию окна:

$$a(x_i, x) = \left(1 - \frac{\|x_i - x\|^2}{2R^2}\right)^3 \quad \text{если} \quad \|x_i - x\|^2 < R, \quad (11)$$

иначе $a(x_i, x) = 0$. ψ — еще одна скалярная функция для нормализации, которая может быть установлена в нашей реализации как:

$$\psi(x) = 1 \quad \text{или} \quad \psi(x) = \sum_{i \in N(x, R)} a(x_i, x). \quad (12)$$

Авторы используют $\psi(x) = 1$, так как изменения в плотности частиц являются важной особенностью для моделирования жидкостей. Для фильтра g они просто используют регулярную сетку для хранения значений фильтра, но применяют линейную интерполяцию, чтобы сделать g непрерывной функцией. Кроме того, авторы используют отображение $\Lambda(r)$ единичного шара в единичный куб для реализации сферических фильтров, как показано на рисунке 1. Промежуточное отображение координат Λ предоставляет гибкость для реализации различных пространственных форм, сохраняя при этом преимущества регулярной сетки для хранения и поиска значений фильтра.

7 Обучение механики жидкостей

Наша цель — изучить механику жидкостей, наблюдая за движением частиц. Входными данными для нашей ConvNet является набор частиц с соответствующими

щими характеристиками. Поскольку положение само по себе не является характеристикой, а просто определяет положение частицы в пространстве, мы должны присвоить каждой частице вектор характеристик. Вектор характеристик, который мы используем, состоит из постоянного скаляра 1, скорости v и вязкости ν . Таким образом, частица p_i на шаге n с её положением и вектором характеристик представляет собой кортеж $(x_n^i, [1, v_n^i, \nu_i])$.

Определение скорости в явном виде как входной характеристики позволяет нам вычислять промежуточные скорости и положения, и применять внешние силы, передавая эту информацию в сеть. Мы вычисляем промежуточные положения x_n^{*i} и скорости v_n^{*i} , начиная с шага n , с помощью метода Хьюна:

$$v_n^{*i} = v_n^i + \Delta t a_{\text{ext}} \quad (13)$$

$$x_n^{*i} = x_n^i + \Delta t \left(v_n^i + \frac{v_n^{*i}}{2} \right). \quad (14)$$

Вектор a_{ext} — ускорение, через которое мы можем применять внешние силы для управления жидкостью или просто применять гравитацию. Промежуточные положения и скорости не учитывают взаимодействия между частицами или сценой, которые будем реализовывать с помощью ConvNet. Чтобы позволить сети обрабатывать столкновения с окружением, мы определяем второй набор статических частиц s_j . Мы выбираем частицы на границах сцены с нормальными n_j как векторы характеристик, т.е. $s_j = (x_j, [n_j])$.

Сеть реализует функцию:

$$[\Delta x_1, \dots, \Delta x_N] = \text{ConvNet}(\{p_n^{*1}, \dots, p_n^{*N}\}, \{s_1, \dots, s_M\}), \quad (15)$$

которая использует свертки для комбинирования характеристик из обоих наборов частиц. Δx — коррекция положения, которая учитывает все взаимодействия частиц, включая обработку столкновений со сценой. Наконец, применяется коррекцию для обновления положений и скоростей для шага $n + 1$:

$$x_{n+1}^i = x_n^{*i} + \Delta x_i \quad (16)$$

$$v_{n+1}^i = \frac{x_{n+1}^i - x_n^i}{\Delta t}. \quad (17)$$

Обратите внимание, что обновленное положение x_{n+1}^i зависит от вектора выхода Δx_i и позволяет непосредственно определять нашу цель обучения на основе положений частиц.

8 Заключение

Предложенный подход [1] позволяет эффективно моделировать жидкости с использованием непрерывных сверток в нейронных сетях. Это улучшает точность и скорость симуляции по сравнению с традиционными графовыми методами. Еще интересная практическая работа представлена в [2].




Рис. 2: Схема сети.




Рис. 3: Пример работы.

Список литературы

- [1] Benjamin Ummenhofer, Lukas Prantl, Nils Thuerey, and Vladlen Koltun. Lagrangian fluid simulation with continuous convolutions. In *International Conference on Learning Representations*, 2019.
- [2] Alvaro Sanchez-Gonzalez, Jonathan Godwin, Tobias Pfaff, Rex Ying, Jure Leskovec, and Peter Battaglia. Learning to simulate complex physics with graph networks. In *International conference on machine learning*, pages 8459–8468. PMLR, 2020.