

Galerkin Neural Networks и функции Грина

Андрей Веприков

ИАД

Осень 2025

Мотивация

Задача:

- Решение дифференциальных уравнений (PDE)
- Физика, инженерия, финансы
- Классика: FEM, FDM

Новый подход:

- Нейросети как аппроксиматоры
- Вариационная формулировка (устойчивость, априорные оценки)
- Переход к операторному обучению

Цель презентации

Показать, как метод Галёркина и функции Грина объединяются с нейросетями для решения PDE

Сильная постановка задачи

Линейное эллиптическое уравнение

$$\mathcal{L}u = f \text{ в } \Omega, \quad \mathcal{B}u = g \text{ на } \partial\Omega$$

Пример: уравнение Пуассона с Дирихле

$$-\Delta u = f \text{ в } \Omega, \quad u = 0 \text{ на } \partial\Omega$$

- $\mathcal{L}$ – дифференциальный оператор (например, $-\operatorname{div}(\nabla \cdot)$)
- f – правая часть (источники, нагрузка)
- u – искомое решение (температура, потенциал, давление)

От сильной к слабой постановке

Идея: требуем выполнения уравнения «в среднем» по тестовым функциям v

- ❶ Умножаем уравнение на $v \in V$ и интегрируем:

$$\int_{\Omega} (-\Delta u) v \, dx = \int_{\Omega} f v \, dx$$

- ❷ Интегрируем по частям (формула Грина):

$$\int_{\Omega} \nabla u \cdot \nabla v \, dx - \underbrace{\int_{\partial\Omega} \frac{\partial u}{\partial n} v \, dS}_{=0 \text{ при } v|_{\partial\Omega}=0} = \int_{\Omega} f v \, dx$$

- ❸ Получаем слабую форму:

$$\int_{\Omega} \nabla u \cdot \nabla v \, dx = \int_{\Omega} f v \, dx \quad \forall v \in V$$

Билинейная форма и линейный функционал

Определения

$$a(u, v) := \int_{\Omega} \nabla u \cdot \nabla v \, dx, \quad \ell(v) := \int_{\Omega} f v \, dx$$

Слабая постановка: найти $u \in V = H_0^1(\Omega)$ такое, что

$$a(u, v) = \ell(v) \quad \forall v \in V$$

Свойства $a(\cdot, \cdot)$:

- Билинейность
- Симметрия

Следствие:

- Существование решения
- Единственность
- Устойчивость

Метод Галёркина: конечномерная проекция

Проблема: V —бесконечномерное пространство

Решение: выбираем конечномерное подпространство $V_h \subset V$, $\dim V_h = N$

Галёркин-постановка

Найти $u_h \in V_h$ такое, что

$$a(u_h, v_h) = \ell(v_h) \quad \forall v_h \in V_h$$

- Выбираем базис $\{\phi_1, \dots, \phi_N\}$ в V_h
- Разложение: $u_h(x) = \sum_{j=1}^N c_j \phi_j(x)$
- Тестируем на базисных функциях: $v_h = \phi_i, i = 1, \dots, N$

Система линейных уравнений

Подставляем $u_h = \sum_j c_j \phi_j$ и $v_h = \phi_i$ в $a(u_h, v_h) = \ell(v_h)$:

$$\sum_{j=1}^N c_j a(\phi_j, \phi_i) = \ell(\phi_i), \quad i = 1, \dots, N$$

Матричная форма

$$\mathbf{A} \cdot \mathbf{c} = \mathbf{b}$$

где

$$A_{ij} = a(\phi_j, \phi_i), \quad b_i = \ell(\phi_i)$$

Решение: $\mathbf{c} = \mathbf{A}^{-1}\mathbf{b}$ (если A невырождена)

Галёркин vs Коллокация

Коллокация:

$$\mathcal{L}u_h(x_j) = f(x_j)$$

в точках $\{x_j\}_{j=1}^M$

Минусы:

- Чувствительность к выбору точек
- Нет энергетической структуры
- Хуже для жёстких операторов

Галёркин:

$$a(u_h, v_i) = \ell(v_i)$$

для базиса $\{v_i\}_{i=1}^N$

Плюсы:

- Энергетический баланс
- Устойчивость
- Априорные оценки

Вывод

Галёркин часто предпочтительнее для эллиптических задач

Нейросети в методе Галёркина

Идея: заменить фиксированный базис на обучаемый

Три подхода

❶ **Прямая параметризация решения:**

$u_\theta(x)$ —нейросеть с параметрами θ

❷ **Параметризация базиса:**

$$u_h(x) = \sum_{i=1}^N c_i \phi_i^\theta(x)$$

❸ **Параметризация оператора** (функция Грина —позже)

Цель обучения: минимизировать невязку Галёркина

Galerkin Neural Networks: постановка

Целевая функция

$$\mathcal{J}(\theta) = \sum_{k=1}^M \left(a(u_\theta, v_k) - \ell(v_k) \right)^2 + \lambda \mathcal{L}_{\text{BC}}(\theta)$$

где:

- $\{v_k\}_{k=1}^M$ — набор тестовых функций (могут быть фиксированными или обучаемыми)
- $\mathcal{L}_{\text{BC}}$ — штраф за нарушение граничных условий
- λ — вес штрафа

Обучение: градиентный спуск по θ (SGD, Adam)

$$\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{J}(\theta)$$

Встраивание граничных условий

Жёсткое (hard):

$$u_\theta(x) = g(x) + \eta(x) n_\theta(x)$$

где $\eta|_{\partial\Omega} = 0$

Плюсы:

- Условия выполнены точно
- Меньше параметров для обучения

Мягкое (soft):

$$\mathcal{L}_{\text{BC}} = \int_{\partial\Omega} |u_\theta - g|^2 dS$$

Минусы:

- Нужно подбирать λ
- Условия выполнены приближённо

Практика

Жёсткое наложение предпочтительнее, когда возможно

Численное интегрирование

Проблема: нужно вычислять

$$a(u_\theta, v_k) = \int_{\Omega} \nabla u_\theta \cdot \nabla v_k \, dx$$

Решение: стохастические квадратуры

- Выборка батча точек $\{x_i\}_{i=1}^B \sim \text{Uniform}(\Omega)$
- Приближение:

$$a(u_\theta, v_k) \approx \frac{|\Omega|}{B} \sum_{i=1}^B \nabla u_\theta(x_i) \cdot \nabla v_k(x_i)$$

- Аналогично для граничных интегралов

Автоматическое дифференцирование

Градиенты ∇u_θ вычисляются через autograd (PyTorch, JAX)

Мотивация: операторное обучение

До сих пор: решали задачу для конкретной правой части f

Вопрос: что если f меняется часто?

- Разные сценарии нагрузки
- Параметрические исследования
- Обратные задачи

Идея

Вместо обучения решения u для каждого f , **обучим оператор** $\mathcal{G} : f \mapsto u$

Инструмент: функции Грина – фундаментальные решения линейных операторов

Функция Грина

Определение

Функция Грина $G(x, \xi)$ удовлетворяет:

$$\mathcal{L}_x G(x, \xi) = \delta(x - \xi), \quad \mathcal{B}_x G(x, \xi) = 0$$

Интерпретация:

- $G(x, \xi)$ — отклик системы в точке x на точечный источник в ξ
- $\delta(x - \xi)$ — дельта-функция Дирака

Представление решения

$$u(x) = \int_{\Omega} G(x, \xi) f(\xi) d\xi + u_{\text{hom}}(x)$$

где u_{hom} — решение однородной задачи (учёт граничных условий)

Обучение функции Грина: $G_\theta(x, \xi)$

Идея: параметризуем G нейросетью с двумя входами (x, ξ)

Условие обучения (слабая форма)

Для всех тестовых v :

$$\int_{\Omega} \mathcal{L}_x G_\theta(x, \xi) v(x) dx \approx v(\xi)$$

Целевая функция:

$$\mathcal{J}(\theta) = \sum_{k=1}^M \sum_{j=1}^P \left| \int_{\Omega} \mathcal{L}_x G_\theta(x, \xi_j) v_k(x) dx - v_k(\xi_j) \right|^2$$

+ граничные условия: $\mathcal{B}_x G_\theta(x, \xi) = 0$ для всех ξ

Галёркин + функции Грина

Галёркин:

- Вариационная постановка
- Проекция на V_h
- Энергетическая оптимальность
- Решение для конкретного f

Функции Грина:

- Операторная постановка
- Интегральное представление
- Переносимость на разные f
- Обучение оператора $\mathcal{G}$

Синтез

Можно использовать Галёркин-условия для обучения G_θ :

$$a(G_\theta(\cdot, \xi), v) = v(\xi) \quad \forall v \in V_h$$