

Neural ODE.

Насыров Р.Р

МФТИ

20 декабря 2025 г.

Когда применять:

- Нерегулярно-семплированные временные ряды
- Моделирование физических процессов
- Непрерывная динамика процесса
- Компромисс: скорость/точность

Когда не применять:

- Высокая размерность данных
- Простые регулярные временные ряды
- Когда нужна интерпретация

Сравнение с RNN и ResNet

RNN:

Neural ODE

ResNet

$$h_{t+1} = h_t + f(h_t, \theta) \qquad \frac{dh(t)}{dt} = f(h(t), t, \theta) \qquad h_{t+1} = h_t + f(h_t, t, \theta)$$

- Дискретизуя автономные ODE, получим RNN.
- Дискретизуя общие ODE, получим ResNet.

Задача предсказания временного ряда

Алгоритм Neural ODE

- Эволюция $h(t)$ описывается ODE, в котором векторное поле f задается нейросетью:

$$\frac{dh(t)}{dt} = f_{\theta}(h(t), t)$$

- Генеративная модель:

$$\begin{cases} h_{t_0} \sim p(h_{t_0}) \\ h_{t_i} = \text{ODESolve}(h_{t_0}, f_{\theta}, t_i) \\ x_{t_i} \sim p_{\phi}(x|h_{t_i}) \end{cases}$$

Где t_i — времена, в которых нужно вычислить временной ряд, x — значение, соответствующее h , p_{ϕ} — параметр декодера.





Рис.: Отличие residual- (слева) и ODE- (справа) нейросетей

Обучение




$$L(h(t_1)) = L \left(h(t_0) + \int_{t_0}^T f(h(t), t, \theta) dt \right) = L(\text{ODESolve}(h(t_0), f, t_0, t_1, \theta))$$

$$L(h(t_1)) = L \left(h(t_0) + \int_{t_0}^T f(h(t), t, \theta) dt \right) = L(ODESolve(h(t_0), f, t_0, t_1, \theta))$$

- Чтобы посчитать градиент L по θ , найдем сначала градиент по скрытому состоянию $h(t)$ и получим *adjoint state* $a(t) = \frac{\partial L}{\partial h(t)}$
- Его динамика задается ODE (непрерывный аналог chain rule):

$$\frac{da(t)}{dt} = -a(t)^T \frac{\partial f}{\partial h}$$

$$\frac{da(t)}{dt} = -a(t)^T \frac{\partial f}{\partial h}$$



$$L(h(t_1)) = L \left(h(t_0) + \int_{t_0}^T f(h(t), t, \theta) dt \right) = L(ODESolve(h(t_0), f, t_0, t_1, \theta))$$

Итого backpropagation процесс:

- Вычисляется $L(h(t_1))$.
- Вычисляется лосс $L(h(t_1))$.
- Adjoint state $a(t)$ инициализируется t_1 как $a(t_1) = \frac{\partial L}{\partial h(t_1)}$.
- Adjoint dynamics решается обратно во времени:

$$\frac{da(t)}{dt} = -a(t)^T \frac{\partial f}{\partial h}$$

- Вычисляем градиент по параметрам:

$$\frac{dL}{d\theta} = - \int_{t_1}^{t_0} a(t)^T \frac{\partial f}{\partial \theta} dt$$

Результаты

	Test Error	# Params	Memory	Time
1-Layer MLP [†]	1.60%	0.24 M	-	-
ResNet	0.41%	0.60 M	$\mathcal{O}(L)$	$\mathcal{O}(L)$
RK-Net	0.47%	0.22 M	$\mathcal{O}(\tilde{L})$	$\mathcal{O}(\tilde{L})$
ODE-Net	0.42%	0.22 M	$\mathcal{O}(1)$	$\mathcal{O}(\tilde{L})$

# Observations	30/100	50/100	100/100
RNN	0.3937	0.3202	0.1813
Latent ODE	0.1642	0.1502	0.1346

Выводы:

- 1 ODE при кратно меньшем числе параметров достигает такой же ошибки, как и ResNet
- 2 Latent ODE показывает меньший RMSE в предсказании временного ряда
- 3 При уменьшении количества наблюдений качество падает меньше, чем у RNN в задаче предсказания временного ряда.

Литература

- 1 Ricky TQ Chen et al. “Neural ordinary differential equations”. In: Advances in neural information processing systems 31 (2018).
- 2 Nan Du et al. “Recurrent marked temporal point processes: Embedding event history to vector”. In: Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining. 2016, pp. 1555–1564.
- 3 Patrick Kidger et al. “Neural controlled differential equations for irregular time series”. In: Advances in neural information processing systems 33 (2020), pp. 6696–6707.
- 4 Hongyuan Mei and Jason M Eisner. “The neural hawkes process: A neurally self-modulating multivariate point process”. In: Advances in neural information processing systems 30 (2017).
- 5 Jakob Gulddahl Rasmussen. “Lecture notes: Temporal point processes and the conditional intensity function”. In: arXiv preprint arXiv:1806.00221 (2018).