

Применение римановой геометрии для классификации пространственно-временных рядов

Даниил Дмитриевич Дорин

Кафедра интеллектуальных систем ФПМИ МФТИ

2025


Постановка задачи классификации многомерных временных рядов

Задано N временных рядов длины T :

$$\{\mathbf{X}_i \mid i = 1, \dots, N\}, \quad \mathbf{X}_i \in \mathbb{R}^{K \times T},$$

где $\mathbf{X}_i$ — многомерный временной ряд. Каждому $\mathbf{X}_i$ соответствует $y_i \in \{1, \dots, C\}$, где C — число классов. Требуется построить модель классификации g :

$$g : \mathbb{R}^{K \times T} \rightarrow \{1, \dots, C\}.$$



Риманова геометрия в пространстве SPD-матриц

Пространство SPD-матриц образует риманово многообразие — дифференцируемое многообразие, в котором касательное пространство в каждой точке является конечномерным евклидовым пространством:

$$\mathcal{R} = \{\mathbf{R} \in \mathbb{R}^{n \times n} \mid \mathbf{R}^\top = \mathbf{R}, \mathbf{R} \succ 0\}.$$

Геодезическая кривая (кратчайшая) между $\mathbf{R}_1, \mathbf{R}_2$ на многообразии $\mathcal{R}$:

$$\gamma(t) = \mathbf{R}_1^{1/2} \left(\mathbf{R}_1^{-1/2} \mathbf{R}_2 \mathbf{R}_1^{-1/2} \right)^t \mathbf{R}_1^{1/2}, \quad t \in [0, 1].$$

Риманово расстояние (длина кривой):

$$\delta_{\mathcal{R}}(\mathbf{R}_1, \mathbf{R}_2) = \|\text{Log}(\mathbf{R}_1^{-1} \mathbf{R}_2)\|_F = \left(\sum_{i=1}^n \log^2 \lambda_i \right)^{1/2},$$

где λ_i — собственные значения матрицы $\mathbf{R}_1^{-1} \mathbf{R}_2$.

Касательное пространство


Пусть $\gamma(t)$ геодезическая кривая из $\mathbf{R}$ в $\mathbf{R}_i$. Тогда касательный вектор в точке $\mathbf{R}$ определяется как производная этой кривой в нуле:

$$\dot{\gamma}(0) = \left. \frac{d}{dt} \gamma(t) \right|_{t=0} \in T_{\mathbf{R}}.$$

Этот вектор задается логарифмическим отображением (обратимым):

$$\text{Log}_{\mathbf{R}}(\mathbf{R}_i) = \mathbf{R}^{1/2} \text{Log}\left(\mathbf{R}^{-1/2} \mathbf{R}_i \mathbf{R}^{-1/2}\right) \mathbf{R}^{1/2} \in T_{\mathbf{R}}.$$

$$\text{Exp}_{\mathbf{R}}(\mathbf{P}_i) = \mathbf{R}^{1/2} \text{Exp}\left(\mathbf{R}^{-1/2} \mathbf{P}_i \mathbf{R}^{-1/2}\right) \mathbf{R}^{1/2} \in \mathcal{R},$$



Геометрическое риманово среднее

Для множества SPD-матриц $\{\mathbf{R}_i\}_{i=1}^m \subset \mathcal{R}$ можно определить два типа средних:

Евклидово (арифметическое) среднее: $\mathbf{R}_{\text{euc}} = \frac{1}{m} \sum_{i=1}^m \mathbf{R}_i$.

Игнорирует нелинейную геометрию $\mathcal{R}$.

Риманово (геометрическое) среднее:

$$\mathbf{R}_{\text{geom}} = \mathfrak{G}(\mathbf{R}_1, \dots, \mathbf{R}_m) = \arg \min_{\mathbf{R} \in \mathcal{R}} \sum_{i=1}^m \delta_R^2(\mathbf{R}, \mathbf{R}_i).$$

Является естественным аналогом центра массы на многообразии, сохраняет геометрию пространства SPD-матриц. Аналитической формулы не существует; вычисление выполняется итерационно¹.

¹[Maher Moakher](#). “A differential geometric approach to the geometric mean of symmetric positive-definite matrices”. *B: SIAM journal on matrix analysis and applications* 26.3 (2005), с. 735—747.

Переход от временных рядов к SPD-матрицам

Для каждого ряда $\mathbf{X}_i \in \mathbb{R}^{K \times T}$ строится выборочная ковариационная матрица:

$$\mathbf{R}_i = \frac{1}{T-1} \mathbf{X}_i \mathbf{X}_i^\top \in \mathbb{R}^{K \times K}, \quad i = 1, \dots, N.$$

Перед вычислением $\mathbf{R}_i$ каждый канал центрируется.

Если $T > K$ и сигналы линейно независимы, то $\mathbf{R}_i \succ 0$, то есть $\mathbf{R}_i \in \mathcal{R}$. Иначе $\mathbf{R}_i$ может быть вырожденной. Тогда применяется регуляризация (shrinkage):

$$\mathbf{R}_i^{\text{reg}} = (1 - \lambda) \mathbf{R}_i + \lambda \cdot \text{tr}(\mathbf{R}_i) \frac{\mathbf{I}}{K}, \quad \lambda \in (0, 1),$$

как реализовано в библиотеке `pyRiemann`.

После этого $\mathbf{R}_i^{\text{reg}} \in \mathcal{R}$, и можно применять риманову геометрию.


Выбор касательной плоскости

Проекция $\text{Log}_{\mathbf{R}}(\cdot)$ на $T_{\mathcal{R}}$ дает точную линейризацию только в окрестности $\mathbf{R}$.


Если $\mathbf{R}_i, \mathbf{R}_j$ далеко от $\mathbf{R}$, то:

$$\delta_R(\mathbf{R}_i, \mathbf{R}_j) \not\approx \|\text{Log}_{\mathbf{R}}(\mathbf{R}_i) - \text{Log}_{\mathbf{R}}(\mathbf{R}_j)\|_F.$$

Выбор $\mathbf{R} = \mathfrak{G}(\{\mathbf{R}_i\})$ минимизирует искажения, так как все данные лежат локально вокруг среднего.



(a) Geometric mean.



(b) Tangent space projection.

Классификация ковариационных матриц временных рядов

В работе Barachant et al. авторы предлагают два алгоритма классификации²:

1. MDRM (Minimum Distance to Riemannian Mean) Для каждого класса k вычисляется риманово среднее: $\mathbf{R}_{\text{geom}}^{(k)} = \mathfrak{G}(\{\mathbf{R}_i \mid y_i = k\})$. Новый объект $\mathbf{R}_{\text{test}}$ классифицируется по минимальному расстоянию:

$$\hat{k} = \arg \min_k \delta_R(\mathbf{R}_{\text{test}}, \mathbf{R}_{\text{geom}}^{(k)}).$$

2. TSM (Tangent Space Mapping). Сначала вычисляется глобальное среднее:

$$\mathbf{R}_{\text{global}} = \mathfrak{G}(\{\mathbf{R}_i\}_{i=1}^N).$$

Затем все $\mathbf{R}_i$ проецируются в касательное пространство:

$$\mathbf{p}_i = \text{upper}\left(\text{Log}_{\mathbf{R}_{\text{global}}}(\mathbf{R}_i)\right) \in \mathbb{R}^{K(K+1)/2}.$$

После этого применяются классические алгоритмы: LDA, SVM и др.

²Alexandre Barachant и др. “Riemannian geometry applied to BCI classification”. В: *International conference on latent variable analysis and signal separation*. Springer. 2010, с. 629—636.

Применение для классификации сигналов ЭЭГ

В работе Barachant et al.³ авторы сравнивают предложенные алгоритмы на датасете **BCI Competition IV**: 9 испытуемых, 4 класса (правая/левая рука, нога, язык), 22 электрода ЭЭГ, 576 испытаний на испытуемого.

CLASSIFICATION ACCURACY IN 30-FOLD CROSS-VALIDATION

	CSP+LDA	CSP*+LDA (nb. of filters)	MDRM	TSLDA (nb. of var).
S1	78.3	81.8 (14.3)	77.8	80.5 (10.6)
S2	44.7	45.1 (6.6)	44.1	51.3 (13.7)
S3	82.2	83.5 (13.5)	76.8	87.5 (12.6)
S4	59.1	59 (9.2)	54.9	59.3 (13.4)
S5	39.7	42.2 (4)	43.8	45 (15)
S6	50.1	43.3 (3)	47.1	55.3 (23.3)
S7	81	81.5 (9.1)	72	82.1 (11.7)
S8	68.5	69.6 (10)	75.2	84.8 (8.9)
S9	77.4	80 (15.1)	76.6	86.1 (12.2)
mean	64.6 ± 16.6	65.1 ± 17.9 (9.4 ± 4.3)	63.2 ± 15.2	70.2 ± 17.1 (13.5 ± 4.1)

³Alexandre Barachant и др. “Multiclass Brain-Computer Interface Classification by Riemannian Geometry”. В: *IEEE Transactions on Biomedical Engineering* 59.4 (март 2012), с. 920—928. DOI: 10.1109/TBME.2011.2172210. URL: <https://hal.science/hal-00681328>.

DreamNet: глубокая риманова сеть для классификации рядов

Задача: классификация многомерных временных рядов (в работе – видео), где каждый объект описывается ковариационной SPD-матрицей.

Backbone (SPDNet): стек из слоёв BiMap ($\mathbf{X} \mapsto \mathbf{W}^\top \mathbf{X} \mathbf{W}$) и ReEig (нелинейность через обрезку собственных значений).

