

Риманова геометрия и модели прогнозирования

Терентьев Александр

ИАД

23 октября 2025 г.

Ключевые понятия римановой геометрии

Многообразие

Гладкое пространство, каждая точка которого обладает окрестностью, диффеоморфной $\mathbb{R}^n$.

Риманова метрика

Семейство скалярных произведений $g_p(\cdot, \cdot)$ на касательных пространствах $T_p M = \{v = \sum_{i=1}^n v^i \frac{\partial}{\partial x^i}\}|_p$, которое меняется гладко по $p \in M$.

Геодезические кривые

Кривые минимальной длины между точками; удовлетворяют уравнению $\frac{D}{dt}\dot{\gamma}(t) = 0$. При этом расстояние $\gamma(t) = \inf \int \sqrt{g(\dot{\gamma}, \dot{\gamma})}$

Экспоненциальное отображение

Экспоненциальное отображение

Экспоненциальное отображение $\exp_p(v) = u$ — движение вдоль геодезической из точки p с начальной скоростью v .

Логарифмическое отображение

Логарифмическое отображение $\log_p(u) = v$ обратное экспоненциальному

Их название обосновывается тем, что при логарифмической метрике $d(x, y) = |\log(x) - \log(y)|$. Экспоненциальное равно $\exp_p(v) = \exp(v)$, а логарифмическое отображение $\log_p(u) = \log(u)$

Среднее Фреше является обобщением среднего арифметического на метрические пространства. Определим дисперсию Фреше следующим образом

$$\Psi(p) = \sum_{i=1}^N d^2(p, x_i).$$

Если существует и единственна точка пространства M такая, что

$$m = \arg \min_{p \in M} \sum_{i=1}^N d^2(p, x_i)$$

Для логарифмической метрики $d(x, y) = |\log x - \log y|$

$$f\left(\frac{1}{n} \sum_{i=1}^n f^{-1}(x_i)\right) = \exp\left(\frac{1}{n} \sum_{i=1}^n \log x_i\right) = \sqrt[n]{x_1 \cdots x_n}.$$

Пример: пространство SPD-матриц

Пространство

$\mathcal{S}_{++}^n$ — пространство симметричных положительно определённых $n \times n$ матриц.

Метрики

- 1 Лог-Евклидова метрика: $\delta_L(P_1, P_2) = \|\text{Log}(P_1) - \text{Log}(P_2)\|_F$,
- 2 Афинно-инвариантная метрика: $g_P(U, V) = \text{tr}(P^{-1}UP^{-1}V)$
- 3 Фишера-Раа: Пригодна для вероятностных интерпретаций данных
- 4 Метрика на основе разложения Холецкого
- 5 Прокрустова: Измеряет сходство между формами после преобразований

Геодезическая кривая

$$\gamma(t) = P^{1/2} \exp(t P^{-1/2} S P^{-1/2}) P^{1/2}$$

Данные

Временные ряды матриц реализованной ковариации $\{P_t\}_t$, $P_t \in \mathcal{S}_{++}^n$.

Два основных подхода из литературы

- Log-Euclidean / Tangent-space модели: $\log_{p_t}(P_t) \in T_{p_t}$, строят AR/GARCH/VAR в касательном пространстве, затем $\exp_{p_t}$ для предсказания.
- Интринсивные Riemannian AR (geodesic AR): прогноз как движение вдоль геодезической, параметризованное векторами скорости в касательном пространстве; модели вида $\log_p(P_{t+1}) = A \log_p(P_t) + \varepsilon_t$ с учётом параллельного переноса.

SPD-многообразие в финансовых задачах

- Ковариационные матрицы доходностей: $X_t \in \mathcal{P}_n$
- Экстраполяция во времени — прогноз будущих ковариационных матриц (например, для портфельной оптимизации)
- Используем риманову метрику для учета геометрии SPD-многообразия

Формула Log-Euclidean метрики

$$\text{dist}(A, B) = \|\log(A) - \log(B)\|_F$$

Подходы для EEG

Идея

представлять ковариационные матрицы EEG как точки на множестве SPD и оперировать ими с помощью римановой геометрии.

Достоинства

Повышенная точность и стабильность, лучшее объединение частотной и пространственной информации, уменьшение зависимости от предварительной фильтрации и явной инверсии источников.

Недостатки

Вычислительная сложность для реального-времени, чувствительность к артефактам, необходимость масштабируемых GNN/приближённых методов и более гибких адаптивных моделей.

Алгоритмы для EEG

Улучшение устойчивости и дискриминации

Расстояния на многообразии (Log-Euclid, Affine-Invariant) лучше отражают структуру данных, чем евклидово.

Tangent-space проекция

Логарифмическая карта переводит SPD в линейное пространство

Методы на SPD-нейросетях

Слои BiMap / ReEig (SPDNet) и модули внимания на многообразии позволяют сохранять SPD-структуру.

Базовые классификаторы

MDRM, Riemannian-ядра для SVM и адаптации GLVQ/RSQ — прямое сравнение и усреднение по геодезическим центрам улучшает робастность к шуму и малым выборкам.

Пространство

Поля направления ветра, ориентированные векторы и тензоры турбулентности часто лежат на многообразиях (сфера S^2 , матрицы SPD).

Преимущество

Агрегация и прогнозы (например, гамма-структуры ковариации) выигрывают от римановой обработки, снижающей артефакты при усреднении и интерполяции.

Риманова оптимизация

- Примеры задач: $\min_{x \in \mathcal{M}} f(x)$, где $\mathcal{M}$ — риманово многообразие.
- Используются геометрические объекты: экспоненциальное отображение, градиент, гессиан на $\mathcal{M}$.

Градиентный спуск на многообразии:

$$x_{k+1} = \text{Exp}_{x_k}(-\alpha_k \cdot \text{grad}f(x_k))$$

Обычно вместо точного экспоненциального отображения используют ретракции (приближённые экспоненциальные отображения).

- 1 **Геодезическая регрессия:** минимум функционала на многообразии аналогично линейной регрессии в касательном пространстве.

$$\min_{\theta \in T_p \mathcal{M}} \sum_i d(\exp_p(\theta x_i), y_i)^2.$$

- 2 **Tangent-space models:** логарифмировать данные в $T_p \mathcal{M}$, применять ARIMA/GARCH/VAR, затем экспонентировать прогнозы.
- 3 **Log-Euclidean** подход для SPD: логарифм матриц по спектру, далее стандартная линейная обработка.

Класс 1: Tangent-space forecasting (лог/эксп подход)

Алгоритм

- 1 Оценить опорную точку p (Karcher mean) на окне.
- 2 Проецировать: $x_t = \log_p(X_t) \in T_p\mathcal{M}$.
- 3 Построить модель в линейном пространстве (AR, VAR, LSTM).
- 4 Прогноз $\hat{x}_{t+h}$ и вернуть $\hat{X}_{t+h} = \exp_p(\hat{x}_{t+h})$.

Достоинства

Простота, использование богатой экосистемы линейных/нейронных моделей.

Недостатки

Аппроксимация локальна; требуется корректный выбор p и учёт переменной кривизны.

Класс 2: Intrinsic geodesic models (геодезическая AR)

Алгоритм

Задаём скорость вдоль геодезики $v_t \in T_{p_t}\mathcal{M}$ и эволюцию вида

$$v_{t+1} = Av_t + \eta_t, \quad p_{t+1} = \exp_{p_t}(v_{t+1}).$$

Преимущества

Уважает глобальную геометрию, корректная эволюция вдоль многообразия.

Недостатки

Требует реализации параллельного переноса $P_{p \rightarrow q} : T_p \rightarrow T_q$ для сопоставления векторов скоростей и интеграции геодезик.

Гауссовские процессы на многообразиях

Ядро зависит от риманова расстояния; прогноз даёт распределение по $\mathcal{M}$.

Стохастические дифференциальные уравнения (SDE)

$$dX_t = V(X_t) dt + \sum_i \Sigma_i(X_t) \circ dW_t^i,$$

где интеграл Стратоновича обеспечивает корректную ковариантную форму.

Сверточные сети

Модули Riemannian layers реализуют операции через лог/эксп или геодезические свёртки.

Рекуррентные сети

RNN/LSTM в касательном пространстве с периодическим проецированием; геометрические RNN, использующие параллельный перенос.

Вариационные методы

Декодер в $T_p\mathcal{M}$ с эксп-картой для генерации на многообразии.

Цель: Прогнозирование матриц реализованной ковариации (RCOV) доходностей активов с учётом их геометрической структуры.

Особенности задачи:

- RCOV-матрицы — симметричные положительно определённые (SPD), лежат на римановом многообразии $\mathcal{S}_{++}^n$.
- Евклидовы методы игнорируют кривизну пространства, что ухудшает точность.
- Необходима модель, учитывающая:
 - нелинейную динамику волатильности;
 - высокую размерность;
 - геометрию SPD-многообразия.

Решение: Геометрически осведомлённая нейросеть (ReSPDNet) с обучением на SPD-многообразии.

ReSPDNet: Адаптация SPDNet (Huang & Van Gool, 2017) для регрессии:

- **BiMap слой:** $X_k = W_k X_{k-1} W_k^T$ — билинейное преобразование SPD-матриц.
- **ReEig слой:** $X_k = U \cdot \max(\epsilon I, \Lambda) \cdot U^T$.
- **Обучение:** стохастический градиентный спуск на многообразии.

GeoHAR: Геометрическое расширение модели Corsi (2009) на SPD-многообразии:

- Использует лаги: дневной, недельный, месячный RCOV.
- Вход: блочно-диагональная матрица из лагов:

$$D_t = \text{diag}(RC_{t-1}, RC_{t-5}^{\text{mean}}, RC_{t-22}^{\text{mean}})$$

- Агрегация через выборку среднее Фреше:

$$\bar{S} = \exp \left(\frac{1}{T} \sum_{t=1}^T \log(S_t) \right)$$

Результаты прогнозирования матриц ковариации

Table 2: Average loss functions and MCS p -values for $n = 50$ assets

Model	Frobenius		Euclidean		Procrustes	
	Avg. loss	p_{MCS}	Avg. loss	p_{MCS}	Avg. loss	p_{MCS}
ReSPNET-LE ₁	3937.07	0.220	25.394	<0.001	3.042	<0.001
ReSPNET-LE ₃	2907.51	0.597	21.329	<0.001	2.343	<0.001
ReSPNET-LE ₅	<u>2813.32</u>	1.000	20.429	0.726	2.183	0.618
ReSPNET-LE ₁₀	3040.69	1.000	<u>20.215</u>	1.000	<u>2.174</u>	1.000
ReSPNET-M ₁	5208.35	0.278	28.380	<0.001	3.628	<0.001
ReSPNET-M ₃	4114.38	0.597	23.947	<0.001	2.831	<0.001
ReSPNET-M ₅	4029.64	0.597	23.549	0.001	2.742	<0.001
ReSPNET-M ₁₀	4065.22	0.597	23.691	<0.001	2.753	<0.001
GeoHAR-LE _{LE}	4246.43	0.597	21.904	0.111	2.178	0.990
GeoHAR-LE _P	3198.60	0.597	21.788	<0.001	2.321	<0.001
GeoHAR-M _{LE}	8445.82	1.000	25.010	0.197	2.816	0.209
GeoHAR-M _P	9347.37	0.849	26.436	0.191	2.992	0.618
Cholesky	3570.12	0.826	21.100	0.044	2.219	0.013
GO-GARCH	10933.75	0.140	35.906	<0.001	2.863	<0.001
RW	3358.24	0.312	22.816	<0.001	2.493	<0.001

Задача прогнозирования ураганов

Цель: Предсказание траекторий $y(t)$, принимающих значения на римановом многообразии M , с использованием обобщённой полиномиальной регрессии.

Модель: Представление траектории $y(t)$ через Bézier-полином $p(t; b)$ с контрольными точками $b = (b_1, \dots, b_n) \in M^n$:

$$\min_{b \in U^n} H(b) := \sum_{i=1}^m \text{dist}^2(y_i, p(t_i; b))$$

где $y_i = y(t_i)$ — наблюдаемые точки, dist — риманово расстояние, U — нормальная окрестность.

Коэффициент детерминации:

$$R^2 = 1 - \frac{H_{\min}}{G_{\min}}, \quad G(x) := \sum_{i=1}^m \text{dist}^2(y_i, x)$$

где $G_{\min}$ достигается в фреше-среднем $\bar{y}$.

Алгоритм: Ridge-регрессия на многообразии

Регуляризация: Добавление геометрически осмысленного штрафа — расстояния Махаланобиса до априорных данных $B = \{b^{(j)}\}$:

$$F_{p,S}(b) = H(b) + \lambda \cdot g_p(S \cdot \log_p b, \log_p b)$$

где $S = E^{-1}$ — оператор точности, E — ковариация в экспоненциальной карте:

$$E = \frac{1}{I} \sum_{j=1}^I \log_p b^{(j)} \cdot \log_p b^{(j)T}$$

Градиент: Используется риманов градиентный спуск. Для $f(b) = g_p(S \log_p b, \log_p b)$:

$$\nabla f = 2 \cdot d \log_p(\exp_p(S \log_p b))$$

Предсказание: По частичной траектории $y_1, \dots, y_{i-1}$:

$$\hat{y}_i := p(t_i; b^*), \quad b^* = \arg \min F_{p,S}(b)$$

- 1 Для быстрого прототипа: Log-Euclidean / tangent-space AR как baseline.
- 2 Для более точной модели: intrinsic geodesic AR или manifold GP с учётом параллельного переноса.
- 3 Для сложных данных (пространственно-временных): комбинировать спектральные методы на многообразии с нейросетями в касательных пространствах.
- 4 Всегда контролируйте численную устойчивость: регуляризация, проверка положительной определённости, анализ остатков на многообразии.