

Спектральные многообразия и динамика оптимизации

Игорь Игнашин

Кафедра интеллектуальных систем, ФПМИ МФТИ

2025


Постановка задачи

Пусть $x_1, \dots, x_n \in \mathbb{R}^d$ лежат на гладком многообразии $\mathcal{M}$ малой размерности.

Цель: найти низкоразмерное представление $y_i \in \mathbb{R}^m$, $m \ll d$, такое, чтобы сохранялась *геометрия данных*.

Интуиция: высокоразмерные данные (например, изображения или состояния модели) часто «живут» на подпространствах малой размерности — это и есть **гипотеза многообразия** (manifold hypothesis).

Пример: развёртывание двумерного «свисс-ролла» без разрывов — извлечение скрытой координатной структуры из нелинейного вложения.



Что такое многообразие и зачем его изучать

Определение: r -мерное многообразие $\mathcal{M} \subset \mathbb{R}^d$ — это множество, локально диффеоморфное $\mathbb{R}^r$.

Интуиция: поверхность $\mathcal{M}$ может быть нелинейно «вложена» в $\mathbb{R}^d$, но в каждой малой окрестности она выглядит как плоское пространство размерности r .

Зачем изучать многообразия:

- ▶ Они описывают **внутреннюю геометрию данных** и их степени свободы.
- ▶ Позволяют строить **низкоразмерные представления**, сохраняющие структуру данных.
- ▶ Служат основой для методов **регуляризации, кластеризации и визуализации**.

Цель: понять геометрическую структуру данных через локальные взаимосвязи точек и восстановить её в низкоразмерном пространстве.

Isomap: построение графа и аппроксимация геодезических расстояний [1]

Идея: аппроксимировать *геодезические расстояния* на многообразии $\mathcal{M}$ через граф ближайших соседей и использовать их для построения низкоразмерного вложения.

Этап 1. Построение графа соседей. Для каждой точки x_i выбираем множество ближайших соседей $\mathcal{N}_k(x_i)$ и задаём взвешенный граф:

$$W_{ij} = \begin{cases} \|x_i - x_j\|, & x_j \in \mathcal{N}_k(x_i), \\ 0, & \text{иначе.} \end{cases}$$

$$G = (V, E), \quad V = \{x_i\}, \quad E = \{(i, j) : W_{ij} > 0\}.$$

Этап 2. Аппроксимация геодезических расстояний.

$$d_G(i, j) = \min_{\pi: i \rightarrow j} \sum_{(p, q) \in \pi} W_{pq},$$

где π — путь в графе G .

$d_G(i, j)$ приближает истинное геодезическое расстояние $d_{\mathcal{M}}(x_i, x_j)$ вдоль поверхности многообразия.

Isomap: MDS и спектральное решение [1]

Этап 3. Многомерное шкалирование (MDS).

Находим вложение $Y = [y_1, \dots, y_N]^T \in \mathbb{R}^{N \times m}$, минимизирующее функционал:

$$E(Y) = \sum_{i < j} (\|y_i - y_j\| - d_G(i, j))^2.$$

Эквивалентная спектральная формулировка:

пусть $D_G^{(2)} = [d_G(i, j)^2]$, тогда центруем матрицу расстояний:

$$B = -\frac{1}{2} H D_G^{(2)} H, \quad H = I - \frac{1}{N} \mathbf{1} \mathbf{1}^T.$$

Собственное разложение:

$$B v_k = \lambda_k v_k, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq 0.$$

Вложение:

$$y_i = (\sqrt{\lambda_1} v_{1i}, \dots, \sqrt{\lambda_m} v_{mi}),$$

где (λ_k, v_k) — собственные пары B .

Интерпретация: Isomap использует спектр матрицы геодезических расстояний — не оператора, а метрики на многообразии.

Почему евклидово расстояние вводит в заблуждение

Даже если точки x_i, x_j близки в $\mathbb{R}^3$, они могут быть **геодезически далеко** на многообразии $\mathcal{M}$.

Евклидово расстояние: $\|x_i - x_j\|$ vs Геодезическое: $d_{\mathcal{M}}(x_i, x_j)$

Интуиция: свисс-ролл “свёрнут” в 3D — точки с разных витков визуально близки, но чтобы дойти по поверхности, нужно пройти вдоль ленты.




Иллюстрация: красная и синяя точки лежат рядом в 3D, но путь вдоль поверхности (жёлтая линия) значительно длиннее.

Следствие: поэтому разумно полагаться на **ближайших соседей** в выборке, чтобы приближать истинное геодезическое расстояние $d_{\mathcal{M}}(x_i, x_j)$.

От евклидова лапласиана к многообразию

В $\mathbb{R}^d$ оператор Лапласа можно записать как

$$\Delta f = \operatorname{div}(\nabla f), \quad \text{где } \nabla f = \left(\frac{\partial f}{\partial x^1}, \dots, \frac{\partial f}{\partial x^d} \right).$$

Если теперь функция f определена на гладком многообразии $(\mathcal{M}, g)$ с локальными координатами $(x^1, \dots, x^r)$ и метрикой $g_{ij}(x)$, нужно построить аналогичные операторы, учитывающие геометрию пространства.

Идея: градиент — это вектор, переводящий производные df из ковекторного (ко-)пространства в касательное пространство с помощью метрики g_{ij} .

Определения: градиент и дивергенция на многообразии

Пусть $(\mathcal{M}, g)$ — r -мерное риманово многообразие, $x = (x^1, \dots, x^r)$ — локальные координаты, $g_{ij}(x)$ — компоненты метрики, $|g| = \det(g_{ij})$.

1. Градиент. Для функции $f : \mathcal{M} \rightarrow \mathbb{R}$ градиент определяется из условия:

$$\langle \nabla_{\mathcal{M}} f, v \rangle = df(v) \quad \forall v \in T_x \mathcal{M}.$$

В координатах:

$$g_{ij}(\nabla f)^i v^j = \frac{\partial f}{\partial x^k} v^k \Rightarrow \boxed{(\nabla f)^i = g^{ij} \frac{\partial f}{\partial x^j}},$$

где g^{ij} — обратная матрица к g_{ij} .

2. Дивергенция. Для векторного поля $v = v^i \partial_i$ определим:

$$\boxed{\operatorname{div} v = \frac{1}{\sqrt{|g|}} \frac{\partial}{\partial x^i} (\sqrt{|g|} v^i)}.$$

Эта формула — координатное выражение оператора $\nabla_i v^i$, где ∇_i — ковариантная производная, и $\sqrt{|g|}$ появляется из объёмной формы.

Вывод оператора Лапласа–Бельтрами

Пусть $(\mathcal{M}, g)$ — риманово многообразие с локальными координатами $(x^1, \dots, x^r)$.

1. Градиент. Он определяется из равенства

$$\langle \nabla f, v \rangle = df(v), \quad \forall v \in T_x \mathcal{M},$$

откуда в координатах:

$$(\nabla f)^i = g^{ij} \frac{\partial f}{\partial x^j}.$$

2. Дивергенция. Из предыдущего слайда:

$$\operatorname{div} v = \frac{1}{\sqrt{|g|}} \frac{\partial}{\partial x^i} (\sqrt{|g|} v^i).$$

3. Композиция: применяем div к ∇f :

$$\Delta f = \operatorname{div}(\nabla f) = \frac{1}{\sqrt{|g|}} \frac{\partial}{\partial x^i} \left(\sqrt{|g|} g^{ij} \frac{\partial f}{\partial x^j} \right).$$

При $g_{ij} = \delta_{ij}$ получаем стандартный лапласиан $\Delta f = \sum_i \frac{\partial^2 f}{\partial x_i^2}$.

Свойства оператора Лапласа–Бельтрами

Аналитические свойства:

- ▶ $\Delta_{\mathcal{M}}$ — самосопряжённый и эллиптический дифференциальный оператор второго порядка;
- ▶ спектр $\{-\lambda_k\}$ дискретен и неотрицателен:

$$-\Delta\psi_k = \lambda_k\psi_k, \quad 0 = \lambda_1 < \lambda_2 \leq \dots;$$

- ▶ функции $\{\psi_k\}$ образуют ортонормированный базис $L^2(\mathcal{M})$.

Физический смысл:

- ▶ Оператор описывает диффузию и теплопроводность на поверхности:

$$\partial_t u = \Delta_{\mathcal{M}} u;$$

- ▶ собственные функции ψ_k — формы стоячих волн (mode shapes), а λ_k — частоты колебаний;
- ▶ спектр $\{\lambda_k\}$ кодирует **геометрию многообразия** — «по спектру можно услышать форму поверхности» (Mark Кас, 1966).

Физический смысл оператора $\Delta_{\mathcal{M}}$

1. Уравнение диффузии (теплопроводности):

$$\partial_t u(x, t) = \Delta_{\mathcal{M}} u(x, t),$$

где $u(x, t)$ — температура в точке $x \in \mathcal{M}$ в момент времени t .

Интерпретация:

- ▶ значение $\Delta_{\mathcal{M}} u(x, t)$ показывает, насколько $u(x, t)$ отличается от среднего по малой окрестности точки x ;
- ▶ положительное значение $\Delta_{\mathcal{M}} u$ — из точки утекает тепло, отрицательное — в неё притекает;
- ▶ процесс распространяется *вдоль поверхности*, а не в $\mathbb{R}^d$.

Геометрическая интерпретация: скорость выравнивания температуры зависит от кривизны $\mathcal{M}$ и метрики g_{ij} :

диффузия чувствует форму поверхности.

Колебания и спектр оператора $\Delta_{\mathcal{M}}$

2. Волновое уравнение:

$$\partial_{tt} u(x, t) = c^2 \Delta_{\mathcal{M}} u(x, t), \quad u(x, 0) = u_0(x).$$

Решение через спектральное разложение:

$$u(x, t) = \sum_{k=1}^{\infty} A_k \psi_k(x) \cos(c \sqrt{\lambda_k} t),$$

где $-\Delta_{\mathcal{M}} \psi_k = \lambda_k \psi_k$.

Интерпретация:

- ▶ $\psi_k(x)$ — **форма стоячей волны** (mode shape);
- ▶ $\omega_k = c\sqrt{\lambda_k}$ — **собственная частота колебаний**;
- ▶ малые λ_k соответствуют *глобальным, медленным модам*, большие — *локальным, быстро колеблющимся*.

Следствие: спектр $\{\lambda_k\}$ кодирует геометрию $\mathcal{M}$:

по спектру можно «услышать» форму многообразия.

От спектра к дискретному оператору

В реальных данных многообразие $\mathcal{M}$ не задано аналитически — есть только выборка точек $\{x_i\}_{i=1}^N \subset \mathbb{R}^d$.

Идея: аппроксимировать оператор Лапласа–Бельтрами $\Delta_{\mathcal{M}}$ через **граф** ближайших соседей, отражающий локальную геометрию данных.

Построение:

1. Строим k -NN граф $G = (V, E)$, где $V = \{x_i\}$, а рёбра соединяют ближайшие точки.
2. Определяем **веса сходства** между вершинами:

$$W_{ij} = \exp\left(-\frac{\|x_i - x_j\|^2}{t}\right), \quad W_{ij} = 0, (i, j) \notin E.$$

3. Вводим **матрицу степеней**:

$$D_{ii} = \sum_j W_{ij}, \quad L = D - W.$$

Смысл: оператор L действует на функции f на графе как

$$(Lf)_i = \sum_j W_{ij} (f_i - f_j),$$

что является дискретной аппроксимацией $\Delta_{\mathcal{M}} f(x_i)$.

Аппроксимация оператора Лапласа–Бельтрами

Пусть $f : \mathcal{M} \rightarrow \mathbb{R}$ — гладкая функция, а точки $\{x_i\}_{i=1}^N$ равномерно сэмплированы на $\mathcal{M}$.

1. Непрерывное представление через гауссово ядро:

$$(\Delta_{\mathcal{M}} f)(x) \propto \lim_{t \rightarrow 0} \frac{1}{t} \int_{\mathcal{M}} K_t(x, y) [f(y) - f(x)] dy, \quad K_t(x, y) = \frac{1}{(4\pi t)^{r/2}} e^{-\frac{\|x-y\|^2}{4t}}.$$

Дискретная аппроксимация:

$$(L_t f)_i = \frac{1}{tN} \sum_{j=1}^N K_t(x_i, x_j) [f(x_j) - f(x_i)].$$

2. Локальное разложение при $t \rightarrow 0$: в нормальных координатах многообразия

$$\int_{\mathcal{M}} K_t(x, y) [f(y) - f(x)] dy = C_1 t \Delta_{\mathcal{M}} f(x) + O(t^{3/2}), \quad C_1 = \frac{1}{2} \int_{\mathbb{R}^r} \|u\|^2 e^{-\|u\|^2} du.$$

Следовательно:

$$\lim_{t \rightarrow 0, N \rightarrow \infty} \frac{1}{t} (L_t f)(x_i) = C_1 (\Delta_{\mathcal{M}} f)(x_i).$$

Таким образом, дискретный оператор $L = D - W$ аппроксимирует $-\Delta_{\mathcal{M}}$.

Метод Laplacian Eigenmaps [2]

Цель: восстановить координаты на многообразии по собственным векторам L .

Решаем обобщённую задачу:

$$Lf = \lambda Df, \quad f_1, \dots, f_m \text{ — собственные векторы для малых } \lambda.$$

Вложение:

$$x_i \mapsto y_i = (f_1(x_i), f_2(x_i), \dots, f_m(x_i)).$$

Интерпретация:

- ▶ f_k аппроксимируют собственные функции ψ_k оператора $\Delta_{\mathcal{M}}$;
- ▶ координаты y_i описывают *гладкие направления* на многообразии;
- ▶ малые λ_k соответствуют крупномасштабным структурам данных.

Diffusion Maps: случайное блуждание [3]

Идея: рассматриваем точки $\{x_i\}_{i=1}^N$ как узлы графа, между которыми частица может переходить с вероятностью

$$W_{ij} = \exp\left(-\frac{\|x_i - x_j\|^2}{\varepsilon}\right), \quad P = D^{-1}W.$$

P_{ij} — вероятность перехода $x_i \rightarrow x_j$ за один шаг.

Интерпретация: на графе происходит *диффузия частиц* — аналог теплопроводности на многообразии. Малые t показывают локальные связи (кластеры), большие t — глобальную структуру.

Спектральная перспектива диффузии

Рассмотрим случайное блуждание по графу:

$$P = D^{-1}W, \quad P_{ij} = \Pr(x_i \rightarrow x_j),$$

где $W_{ij} = e^{-\|x_i - x_j\|^2/\varepsilon}$ — веса рёбер, а $D_{ii} = \sum_j W_{ij}$.

P — стохастическая матрица: строки нормированы по вероятности.

Собственные функции и значения:

$$P\psi_\ell = \lambda_\ell\psi_\ell, \quad 1 = \lambda_0 > \lambda_1 \geq \lambda_2 \geq \dots \geq 0.$$

- ▶ $\psi_\ell(x)$ — **собственные моды диффузии**: направления, вдоль которых вероятностная масса «растекается» по графу;
- ▶ λ_ℓ — **коэффициенты затухания**: чем меньше λ_ℓ , тем быстрее исчезает соответствующая компонента распределения со временем;
- ▶ $\psi_0(x)$ соответствует **стационарному распределению**, где вероятность не меняется.

Связь с оператором Лапласа–Бельтрами: в пределе $\varepsilon \rightarrow 0$ и при плотной выборке

$$P \approx e^{t\Delta_{\mathcal{M}}}, \quad \lambda_\ell^t \approx e^{-t\nu_\ell^2},$$

где ν_ℓ^2 — собственные значения оператора $-\Delta_{\mathcal{M}}$.

То есть спектр P аппроксимирует спектр Лапласа–Бельтрами, а ψ_ℓ — дискретные аналоги собственных функций $\psi_\ell(x)$ на многообразии.

Diffusion Distance и Diffusion Maps

1. Эволюция распределения вероятности. Пусть $p_t(x_i, \cdot)$ — вероятность попасть из точки x_i в другие точки за t шагов:

$$p_t(x_i, x_j) = (P^t)_{ij}.$$

2. Diffusion distance: метрика, измеряющая *насколько похожи вероятностные окрестности* точек:

$$D_t(x_i, x_j)^2 = \sum_{k=1}^N \frac{[p_t(x_i, x_k) - p_t(x_j, x_k)]^2}{\phi_0(x_k)},$$

где ϕ_0 — стационарное распределение, то есть $P^\top \phi_0 = \phi_0$.

Используя спектральное разложение $P\psi_\ell = \lambda_\ell \psi_\ell$, получаем компактную форму:

$$D_t(x_i, x_j)^2 = \sum_{\ell \geq 1} \lambda_\ell^{2t} [\psi_\ell(x_i) - \psi_\ell(x_j)]^2.$$

3. Diffusion map: вложение, сохраняющее эти расстояния:

$$\Psi_t(x_i) = (\lambda_1^t \psi_1(x_i), \lambda_2^t \psi_2(x_i), \dots, \lambda_m^t \psi_m(x_i)).$$

Тогда

$$\|\Psi_t(x_i) - \Psi_t(x_j)\|_2 = D_t(x_i, x_j).$$

Интерпретация: евклидово расстояние в пространстве Ψ_t равно вероятностной «геодезической» близости точек на многообразии — диффузия частиц раскрывает скрытую геометрию данных.

Сравнение Isomap и спектральных подходов

1. Isomap [1]

- ▶ Восстанавливает глобальную структуру данных через аппроксимацию *геодезических расстояний*;
- ▶ Использует многомерное шкалирование (MDS) по матрице кратчайших путей;
- ▶ Хорошо разворачивает «свёрнутые» многообразия, но чувствителен к шуму и разрывам графа соседей.

2. Laplacian Eigenmaps [2]

- ▶ Использует спектр дискретного лапласиана $L = D - W$;
- ▶ Описывает *локальную геометрию* и гладкие направления на многообразии;
- ▶ Прост в реализации, но не учитывает глобальные связи между компонентами.

3. Diffusion Maps [3]

- ▶ Анализирует спектр матрицы переходных вероятностей $P = D^{-1}W$;
- ▶ Интерпретируется как случайное блуждание по графу;
- ▶ Устойчив к шуму, выделяет **медленные моды диффузии**, описывающие глобальные структуры.

Вывод: спектральные методы аппроксимируют операторы на многообразии и обеспечивают устойчивое низкоразмерное представление, согласованное с геометрией данных.

Заключение

Основные выводы:

- ▶ Многообразия дают естественную основу для описания геометрии данных и динамики обучения.
- ▶ Оператор Лапласа–Бельтрами отражает внутреннюю структуру поверхности; его дискретные аналоги (L, P) лежат в основе спектральных методов.
- ▶ Laplacian Eigenmaps и Diffusion Maps реализуют аппроксимацию непрерывных операторов через спектр матриц смежности и степеней.
- ▶ Спектральные координаты соответствуют «гладким модам» данных, связывая геометрию, диффузию и обучение.

Применения:

- ▶ анализ траекторий SGD в многомерном параметрическом пространстве;
- ▶ оценка *эффективной размерности* и плоских минимумов;
- ▶ интерпретация динамики нейросетей через спектр графа параметров.

Ключевые источники: Belkin & Niyogi (2003); Coifman & Lafon (2006); Lafon (2004).



Tenenbaum, J. B., de Silva, V., Langford, J. C. (2000). *A Global Geometric Framework for Nonlinear Dimensionality Reduction (Isomap)*. Science.



Belkin, M., Niyogi, P. (2003). *Laplacian Eigenmaps for Dimensionality Reduction and Data Representation*. Neural Computation.



Coifman, R. R., Lafon, S. (2006). *Diffusion Maps*. Applied and Computational Harmonic Analysis.