

Спектральные многообразия и динамика оптимизации

Игорь Игнашин

Кафедра интеллектуальных систем, ФПМИ МФТИ

2025

Постановка задачи

Пусть $x_1, \dots, x_n \in \mathbb{R}^d$ лежат на гладком многообразии $\mathcal{M}$ малой размерности.

Цель: найти низкоразмерное представление $y_i \in \mathbb{R}^m$, $m \ll d$, такое, чтобы сохранялась *геометрия данных*.

Пример: развёртывание двумерного «свисс-ролла» без разрывов.

Ключевая идея: геометрическая структура $\mathcal{M}$ определяется локальными соседями и оператором Лапласа–Бельтрами.

Что такое многообразие

Определение: r -мерное многообразие $\mathcal{M} \subset \mathbb{R}^d$ — это множество, локально диффеоморфное $\mathbb{R}^r$.

Интуиция: поверхность $\mathcal{M}$ может быть нелинейно «вложена» в $\mathbb{R}^d$, но в каждой малой окрестности она выглядит как плоское пространство размерности r .

Мотивация: в реальных данных (изображения, траектории, параметры сетей) эффективная размерность часто мала — *manifold hypothesis*.

Почему важно изучать многообразия

- ▶ Позволяют понять **геометрию данных** и внутренние степени свободы.
- ▶ Упрощают задачи обучения — снижают размерность признаков.
- ▶ Формируют основу для **регуляризации, кластеризации и визуализации**.

Цель: построить низкоразмерное вложение, сохраняющее локальную структуру $\mathcal{M}$.

Isomap: построение графа и аппроксимация геодезических расстояний [1]

Идея: аппроксимировать *геодезические расстояния* на многообразии $\mathcal{M}$ через граф ближайших соседей и использовать их для построения низкоразмерного вложения.

Этап 1. Построение графа соседей. Для каждой точки x_i выбираем множество ближайших соседей $\mathcal{N}_k(x_i)$ и задаём взвешенный граф:

$$W_{ij} = \begin{cases} \|x_i - x_j\|, & x_j \in \mathcal{N}_k(x_i), \\ 0, & \text{иначе.} \end{cases}$$

$$G = (V, E), \quad V = \{x_i\}, \quad E = \{(i, j) : W_{ij} > 0\}.$$

Этап 2. Аппроксимация геодезических расстояний.

$$d_G(i, j) = \min_{\pi: i \rightarrow j} \sum_{(p, q) \in \pi} W_{pq},$$

где π — путь в графе G .

$d_G(i, j)$ приближает истинное геодезическое расстояние $d_{\mathcal{M}}(x_i, x_j)$ вдоль поверхности многообразия.

Isomap: MDS и спектральное решение [1]

Этап 3. Многомерное шкалирование (MDS).

Находим вложение $Y = [y_1, \dots, y_N]^T \in \mathbb{R}^{N \times m}$, минимизирующее функционал:

$$E(Y) = \sum_{i < j} (\|y_i - y_j\| - d_G(i, j))^2.$$

Эквивалентная спектральная формулировка:

пусть $D_G^{(2)} = [d_G(i, j)^2]$, тогда центруем матрицу расстояний:

$$B = -\frac{1}{2} H D_G^{(2)} H, \quad H = I - \frac{1}{N} \mathbf{1} \mathbf{1}^T.$$

Собственное разложение:

$$B v_k = \lambda_k v_k, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq 0.$$

Вложение:

$$y_i = (\sqrt{\lambda_1} v_{1i}, \dots, \sqrt{\lambda_m} v_{mi}),$$

где (λ_k, v_k) — собственные пары B .

Интерпретация: Isomap использует спектр матрицы геодезических расстояний — не оператора, а метрики на многообразии.

Почему евклидово расстояние вводит в заблуждение

Даже если точки x_i, x_j близки в $\mathbb{R}^3$, они могут быть геодезически далеко на многообразии $\mathcal{M}$.

Евклидово расстояние: $\|x_i - x_j\|$ vs Геодезическое: $d_{\mathcal{M}}(x_i, x_j)$

Интуиция: свисс-ролл “свёрнут” в 3D — точки с разных витков визуально близки, но чтобы дойти по поверхности, нужно пройти вдоль ленты.




Иллюстрация: красная и синяя точки лежат рядом в 3D, но путь вдоль поверхности (жёлтая линия) значительно длиннее.

Следствие: поэтому разумно полагаться на ближайших соседей в выборке, чтобы приближать истинное геодезическое расстояние $d_{\mathcal{M}}(x_i, x_j)$.

Оператор Лапласа–Бельтрами на многообразии

Цель: обобщить оператор Лапласа

$$\Delta f = \sum_i \frac{\partial^2 f}{\partial x_i^2}$$

на случай, когда функция f определена не в $\mathbb{R}^d$, а на гладком римановом многообразии $\mathcal{M}$.

Пусть $\mathcal{M}$ снабжено метрикой $g_{ij}(x)$, которая определяет скалярное произведение в касательном пространстве:

$$\langle u, v \rangle_x = u^\top g(x) v.$$

Определение: оператор Лапласа–Бельтрами действует на функции $f : \mathcal{M} \rightarrow \mathbb{R}$ как

$$\Delta_{\mathcal{M}} f = \operatorname{div}_{\mathcal{M}}(\nabla_{\mathcal{M}} f).$$

Он измеряет «ускорение» функции на поверхности $\mathcal{M}$, то есть насколько $f(x)$ отличается от среднего значения f в малой окрестности точки x .

Как получается выражение для $\Delta_{\mathcal{M}} f$

Пусть локальные координаты на $\mathcal{M}$ заданы как $x = (x^1, \dots, x^r)$, а метрика — матрицей $g_{ij}(x)$, тогда $|g| = \det(g_{ij})$.

1. Градиент на многообразии:

$$(\nabla_{\mathcal{M}} f)^i = g^{ij} \frac{\partial f}{\partial x^j},$$

где g^{ij} — элементы обратной матрицы к g_{ij} .

2. Дивергенция на многообразии: для векторного поля $v = (v^i)$ имеем

$$\operatorname{div}_{\mathcal{M}}(v) = \frac{1}{\sqrt{|g|}} \frac{\partial}{\partial x^i} \left(\sqrt{|g|} v^i \right).$$

3. Подставляем $v = \nabla f$:

$$\Delta_{\mathcal{M}} f = \frac{1}{\sqrt{|g|}} \frac{\partial}{\partial x^i} \left(\sqrt{|g|} g^{ij} \frac{\partial f}{\partial x^j} \right).$$

Свойства:

- ▶ $\Delta_{\mathcal{M}}$ — самосопряжённый эллиптический оператор;
- ▶ собственные функции ψ_k образуют ортонормированный базис $L^2(\mathcal{M})$;
- ▶ спектр $\{\lambda_k\}$ описывает форму $\mathcal{M}$.

Интуиция: от евклидова пространства к многообразию

В $\mathbb{R}^d$ лапласиан измеряет «изгиб» функции:

$$\Delta f(x) \approx \frac{1}{|B_\varepsilon(x)|} \int_{B_\varepsilon(x)} [f(y) - f(x)] dy.$$

На многообразии $\mathcal{M}$ усреднение проводится **по поверхности** — вдоль касательных направлений, с учётом метрики $g_{ij}(x)$.

$$\Delta_{\mathcal{M}} f = \frac{1}{\sqrt{|g|}} \frac{\partial}{\partial x^i} \left(\sqrt{|g|} g^{ij} \frac{\partial f}{\partial x^j} \right)$$

Интерпретация:

- ▶ $\Delta_{\mathcal{M}} f(x)$ показывает, насколько $f(x)$ отклоняется от среднего по локальной геометрии;
- ▶ направление “распространения” функции задаётся структурой $\mathcal{M}$.

Физический смысл оператора $\Delta_{\mathcal{M}}$

Связь с физикой:

$\partial_t u = \Delta_{\mathcal{M}} u \Rightarrow$ диффузия тепла на поверхности;

$\partial_{tt} u = c^2 \Delta u \Rightarrow$ волновые колебания вдоль поверхности.

Функция $u(x, t)$:

- ▶ $x \in \mathcal{M}$ — точка на поверхности;
- ▶ t — время;
- ▶ $u(x, t)$ — температура, смещение или плотность в точке x .

Интерпретация:

- ▶ оператор Δ описывает “утечку” или изгиб поля вдоль $\mathcal{M}$;
- ▶ колебания $u(x, t)$ зависят от геометрии поверхности.

Спектр и волновые моды

Пусть $u(x, t) = \psi(x)e^{i\omega t}$ — стационарная волна на $\mathcal{M}$.

Подставим в волновое уравнение:

$$\partial_{tt}u = c^2 \Delta_{\mathcal{M}}u \quad \Rightarrow \quad -\Delta\psi = \frac{\omega^2}{c^2}\psi.$$

Интерпретация:

- ▶ $\psi_k(x)$ — форма стоячей волны (mode shape);
- ▶ $\lambda_k = \omega_k^2/c^2$ — частота колебаний;
- ▶ малые λ_k — глобальные моды, большие λ_k — локальные детали.

На сфере:

$$-\Delta_{S^2} Y_\ell^m = \frac{\ell(\ell+1)}{R^2} Y_\ell^m,$$

где Y_ℓ^m — сферические гармоники: глобальные формы колебаний поверхности.

От спектра к дискретному оператору

В реальных данных многообразие $\mathcal{M}$ не задано аналитически — есть только выборка точек $\{x_i\}_{i=1}^N \subset \mathbb{R}^d$.

Идея: аппроксимировать оператор Лапласа–Бельтрами $\Delta_{\mathcal{M}}$ через **граф** ближайших соседей, отражающий локальную геометрию данных.

Построение:

1. Строим k -NN граф $G = (V, E)$, где $V = \{x_i\}$, а рёбра соединяют ближайшие точки.
2. Определяем **веса сходства** между вершинами:

$$W_{ij} = \exp\left(-\frac{\|x_i - x_j\|^2}{t}\right), \quad W_{ij} = 0, (i, j) \notin E.$$

3. Вводим **матрицу степеней**:

$$D_{ii} = \sum_j W_{ij}, \quad L = D - W.$$

Смысл: оператор L действует на функции f на графе как

$$(Lf)_i = \sum_j W_{ij} (f_i - f_j),$$

что является дискретной аппроксимацией $\Delta_{\mathcal{M}} f(x_i)$.

Аппроксимация оператора Лапласа–Бельтрами

Пусть $f : \mathcal{M} \rightarrow \mathbb{R}$ — гладкая функция, а точки $\{x_i\}_{i=1}^N$ равномерно сэмплированы на $\mathcal{M}$.

1. Непрерывный оператор через ядро Гаусса:

$$(\Delta_{\mathcal{M}} f)(x) \propto \lim_{t \rightarrow 0} \frac{1}{t} \int_{\mathcal{M}} K_t(x, y) [f(x) - f(y)] dy \approx \frac{1}{tN} \sum_{j=1}^N K_t(x_i, x_j) [f(x_i) - f(x_j)].$$

где $K_t(x, y) = e^{-\frac{\|x-y\|^2}{t}}$, $(L_t f)_i = \frac{1}{tN} \sum_{j=1}^N K_t(x_i, x_j) [f(x_i) - f(x_j)]$.

2. Локальное разложение при $t \rightarrow 0$: в нормальных координатах многообразия

$$\int_{\mathcal{M}} K_t(x, y) [f(x) - f(y)] dy = C_1 t \Delta_{\mathcal{M}} f(x) + O(t^{3/2}),$$

где $C_1 = \frac{1}{2} \int_{\mathbb{R}^d} \|u\|^2 e^{-\|u\|^2} du$.

Следовательно:

$$\lim_{t \rightarrow 0, N \rightarrow \infty} \frac{1}{t} (L_t f)(x_i) = C_1 (\Delta_{\mathcal{M}} f)(x_i).$$

Таким образом, $L = D - W$ аппроксимирует $-\Delta_{\mathcal{M}}$.

Метод Laplacian Eigenmaps [2]

Цель: восстановить координаты на многообразии по собственным векторам L .

Решаем обобщённую задачу:

$$Lf = \lambda Df, \quad f_1, \dots, f_m \text{ — собственные векторы для малых } \lambda.$$

Вложение:

$$x_i \mapsto y_i = (f_1(x_i), f_2(x_i), \dots, f_m(x_i)).$$

Интерпретация:

- ▶ f_k аппроксимируют собственные функции ψ_k оператора $\Delta_{\mathcal{M}}$;
- ▶ координаты y_i описывают *гладкие направления* на многообразии;
- ▶ малые λ_k соответствуют крупномасштабным структурам данных.

Diffusion Maps: случайное блуждание [3]

Идея: рассматриваем точки $\{x_i\}_{i=1}^N$ как узлы графа, между которыми частица может переходить с вероятностью

$$W_{ij} = \exp\left(-\frac{\|x_i - x_j\|^2}{\varepsilon}\right), \quad P = D^{-1}W.$$

P_{ij} — вероятность перехода $x_i \rightarrow x_j$ за один шаг.

Интерпретация: на графе происходит *диффузия частиц* — аналог теплопроводности на многообразии. Малые t показывают локальные связи (кластеры), большие t — глобальную структуру.

Спектральная перспектива диффузии

$$P\psi_\ell = \lambda_\ell \psi_\ell, \quad 1 = \lambda_0 > \lambda_1 \geq \lambda_2 \geq \dots$$

- ▶ ψ_ℓ — собственные моды распространения вероятности;
- ▶ λ_ℓ^t — скорость затухания каждой моды со временем;
- ▶ первые моды описывают *глобальные направления диффузии*.

В пределе $\varepsilon \rightarrow 0$ случайное блуждание аппроксимирует тепловое уравнение:

$$P \approx e^{t\Delta_{\mathcal{M}}}, \quad \lambda_\ell^t \approx e^{-t\nu_\ell^2}.$$

Следствие: спектр P аппроксимирует спектр оператора Лапласа–Бельтрами на $\mathcal{M}$.

Diffusion Distance и координаты

Diffusion distance:

$$D_t(x_i, x_j)^2 = \sum_{\ell \geq 1} \lambda_\ell^{2t} [\psi_\ell(x_i) - \psi_\ell(x_j)]^2.$$

Diffusion map:

$$\Psi_t(x_i) = (\lambda_1^t \psi_1(i), \dots, \lambda_m^t \psi_m(i)).$$

Основное свойство:

$$\|\Psi_t(x_i) - \Psi_t(x_j)\|_2 = D_t(x_i, x_j).$$

Таким образом, евклидово расстояние в пространстве диффузионных координат равно вероятностной «геодезической» близости точек на многообразии — а диффузия частиц раскрывает его скрытую геометрию.

Сравнение Isomap и спектральных подходов

1. Isomap [1]

- ▶ Восстанавливает глобальную структуру данных через аппроксимацию *геодезических расстояний*;
- ▶ Использует многомерное шкалирование (MDS) по матрице кратчайших путей;
- ▶ Хорошо разворачивает «свёрнутые» многообразия, но чувствителен к шуму и разрывам графа соседей.

2. Laplacian Eigenmaps [2]

- ▶ Использует спектр дискретного лапласиана $L = D - W$;
- ▶ Описывает *локальную геометрию* и гладкие направления на многообразии;
- ▶ Прост в реализации, но не учитывает глобальные связи между компонентами.

3. Diffusion Maps [3]

- ▶ Анализирует спектр матрицы переходных вероятностей $P = D^{-1}W$;
- ▶ Интерпретируется как случайное блуждание по графу;
- ▶ Устойчив к шуму, выделяет **медленные моды диффузии**, описывающие глобальные структуры.

Вывод: спектральные методы аппроксимируют операторы на многообразии и обеспечивают устойчивое низкоразмерное представление, согласованное с геометрией данных.

Заключение

Основные выводы:

- ▶ Многообразия дают естественную основу для описания геометрии данных и динамики обучения.
- ▶ Оператор Лапласа–Бельтрами отражает внутреннюю структуру поверхности; его дискретные аналоги (L, P) лежат в основе спектральных методов.
- ▶ Laplacian Eigenmaps и Diffusion Maps реализуют аппроксимацию непрерывных операторов через спектр матриц смежности и степеней.
- ▶ Спектральные координаты соответствуют «гладким модам» данных, связывая геометрию, диффузию и обучение.

Применения:

- ▶ анализ траекторий SGD в многомерном параметрическом пространстве;
- ▶ оценка *эффективной размерности* и плоских минимумов;
- ▶ интерпретация динамики нейросетей через спектр графа параметров.

Ключевые источники: Belkin & Niyogi (2003); Coifman & Lafon (2006); Lafon (2004).



Tenenbaum, J. B., de Silva, V., Langford, J. C. (2000). *A Global Geometric Framework for Nonlinear Dimensionality Reduction (Isomap)*. Science.



Belkin, M., Niyogi, P. (2003). *Laplacian Eigenmaps for Dimensionality Reduction and Data Representation*. Neural Computation.



Coifman, R. R., Lafon, S. (2006). *Diffusion Maps*. Applied and Computational Harmonic Analysis.