

Дано

$G = (V, E)$ , где  $v_i \in V$  — места движиков на голове, а  $e_{ij} \in E$  — силы связи между  $v_i$  и  $v_j$

Задача векторную функцию  $x(v_i, t) \in \mathbb{R}^n$

$$x(t) = x(v_i, t) \in \mathbb{R}^n$$

Прич.  $x(t)$  можно назвать решением диффура с начальными производными:

$$\frac{\partial x(t)}{\partial t} = \operatorname{div} [G(x(t), t) \nabla x(t)],$$

где  $G(x(t), t) = \operatorname{diag}(a(x_i(t), x_j(t)))$   $|E| \times |E|$ ,  
 $a(x_i, x_j)$  — phys. близости между двумя вер.

Применим  $\operatorname{div}$  и  $\nabla$  получим

$$\frac{\partial x(t)}{\partial t} = (A(x(t)) - I)x(t) = \bar{A}(x(t))x(t),$$

$$\text{где } A(x(t)) = (a(x_i, x_j))$$

Если  $\bar{A}$  — не забудь ом.  $x(t)$ , то гамма PDE имеет аналитическое решение

$$x(t) = e^{\bar{A}t} x_0$$

Большинство моделей можно вывести из  
данного PDE.

| Method           | Evolution  | Diffusivity   | Graph $(\mathcal{V}, \mathcal{E}')$                  | Discretisation                       |
|------------------|--|---|--|--------------------------------------|
| ChebNet          | Features $\mathbf{X}$                            | Fixed $a_{ij}$  | Fixed $\mathcal{E}$                                  | Explicit fixed step                  |
| GAT              | Features $\mathbf{X}$                            | $a(\mathbf{x}_i, \mathbf{x}_j)$                                 | Fixed $\mathcal{E}$                                  | Explicit fixed step                  |
| MoNet            | Features $\mathbf{X}$                            | $a(\mathbf{u}_i, \mathbf{u}_j)$                                 | Fixed $\mathcal{E}$                                  | Explicit fixed step                  |
| Transformer      | Features $\mathbf{X}$                            | $a((\mathbf{u}_i, \mathbf{x}_i), (\mathbf{u}_j, \mathbf{x}_j))$ | Fixed $\mathcal{E} = \mathcal{V} \times \mathcal{V}$ | Explicit fixed step                  |
| DeepSet/PointNet | Features $\mathbf{X}$                            | $a(\mathbf{x}_i)$   | Fixed $\mathcal{E} = \emptyset$                      | Explicit fixed step                  |
| DIGL*            | Features $\mathbf{X}$                            | $a(\mathbf{x}_i, \mathbf{x}_j)$                                 | Fixed $\mathcal{E}(\mathbf{U})$                      | Explicit fixed step                  |
| DGCNN/DGM*       | Features $\mathbf{X}$                            | $a(\mathbf{x}_i, \mathbf{x}_j)$                                 | Adaptive $\mathcal{E}(\mathbf{X})$                   | Explicit fixed step                  |
| <b>Beltrami</b>  | Positions $\mathbf{U}$<br>+Features $\mathbf{X}$ | $a((\mathbf{u}_i, \mathbf{x}_i), (\mathbf{u}_j, \mathbf{x}_j))$ | Adaptive $\mathcal{E}(\mathbf{U})$                   | Explicit adaptive step /<br>Implicit |

Table 1: GNN architectures interpreted as particular instances of our framework. \*Attentional variant.

Используя разные методы решения PDE  
получаем как бы дискретизацию данного процесса  
из кинематики момента к единичной схеме GNN

## GRAND

На вход подается  $X_{in}$  - матрица  $|V| \times d$   
Обучаются энодер и денодер  $\varphi, \psi$  и диффузи-  
онный процесс.

На выходе получаем эмбеддинги вершин

$$\mathbf{y} = \psi(X(t)),$$

из  $X(t)$  получаем решение PDE с  
 начальными условиями  $X(0) = \varphi(X_{in})$   
 В качестве обучения для в диффузионном  
 процессе берут:

$$a(\mathbf{x}_i, \mathbf{x}_j) = \text{softmax} \left( \frac{(\mathbf{w}_k \mathbf{x}_i)^T \mathbf{w}_q \mathbf{x}_j}{d_k} \right),$$

из  $\mathbf{w}_q, \mathbf{w}_k$  - обуц. пары.

# Neural Sheaf Diffusion

Решение проблему heterophilic узлов,  
свое теорию пучков.

## Differmer

Основная идея избавиться от проблемы  
матрицы  $\bar{A}(x(t))$ .

Они этого авторы вводят фун. энергии, которая  
показывает качество диффузии на шаге  $k$ :

$$E(X, k; \delta) = \|X - X^{(k)}\|^2 + \lambda \sum_j \delta(\|x_j - x_i\|_2^2)$$

Чем дальше между  $x$  тем меньше  $\delta$ , чтобы в  
процессе диффузии энергия уменьшалась и сис.  
приходит в устойчивое положение, но принципу коно-  
рости мы забудем. Т.е.

$$x_i^{(k+1)} = \left(1 - \tau \sum_{j=1}^{|N|} \bar{A}_{ij}(x_i^{(k)})\right) x_i^{(k)} + \tau \sum_{j=1}^{|N|} \bar{A}_{ij}(x_i^{(k)}) x_j^{(k)}$$

$$E(X^{(k+1)}, k; \delta) \leq E(X^{(k)}, k-1; \delta)$$

Теорема 1 говорит о том, что желаюше  $\bar{A}(x(t))$ ,  
которое будем уменьшать энергию сущ. и будем равна:

$$\text{Diffusivity Inference: } \hat{S}_{ij}^{(k)} = \frac{f(\|\mathbf{z}_i^{(k)} - \mathbf{z}_j^{(k)}\|_2^2)}{\sum_{l=1}^N f(\|\mathbf{z}_i^{(k)} - \mathbf{z}_l^{(k)}\|_2^2)}, \quad 1 \leq i, j \leq N,$$

$$\text{State Updating: } \mathbf{z}_i^{(k+1)} = \underbrace{\left(1 - \tau \sum_{j=1}^N \hat{S}_{ij}^{(k)}\right) \mathbf{z}_i^{(k)}}_{\text{state conservation}} + \underbrace{\tau \sum_{j=1}^N \hat{S}_{ij}^{(k)} \mathbf{z}_j^{(k)}}_{\text{state propagation}}, \quad 1 \leq i \leq N.$$